

数据清洗与格式转换 自动化脚本

2026-6-5

目录

- 一、脚本设计背景与目标3
- 二、适用数据范围3
 - 2.1 文本数据集.....3
 - 2.2 图像数据集.....3
 - 2.3 视频数据集.....4
 - 2.4 数据集获取与路径配置.....4
- 三、脚本总体流程5
- 四、目录结构设计6
 - 4.1 整体目录结构6
 - 4.2 各目录详细说明8
 - 4.3 状态与目录映射关系10
- 五、数据集配置说明.....10
 - 5.1 配置文件作用10
 - 5.2 datasets_config.json 示例.....10
 - 5.3 各数据集配置参数说明.....13
- 六、核心模块设计15
 - 6.1 数据集配置读取模块15
 - 6.2 数据导入与原始文件归档模块.....15
 - 6.3 文本转换模块.....15
 - 6.4 图像转换模块.....15
 - 6.5 视频转换模块.....15
 - 6.6 元数据生成模块16
 - 6.7 基础数据清洗模块.....16
 - 6.8 日志与统计输出模块16
 - 6.9 抽样复核与标注准确率统计模块.....16
- 七、统一格式与字段规则16
 - 7.1 统一存储格式规则.....16
 - 7.2 统一命名规则17
 - 7.3 统一元数据字段设计17
 - 7.4 标签标准化规则19
- 八、数据清洗规则19
 - 8.1 去重规则19
 - 8.2 无效样本过滤规则.....20
 - 8.3 低质量样本过滤规则20
 - 8.4 高风险内容预筛与隔离机制21
 - 8.5 许可合规隔离规则.....21
 - 8.6 统计输出要求22
 - 8.7 标注质量抽样验证规则.....22
- 九、异常处理机制23
 - 9.1 主要异常类型23
 - 9.2 处理策略24
 - 9.3 审计与复核留痕要求24

十、标准化输出示例.....	24
10.1 文本输出示例.....	24
10.1.1 文本样本元数据示例.....	24
10.1.2 具体示例.....	26
10.2 图像输出示例.....	26
10.3 视频输出示例.....	27
10.4 元数据汇总文件示例.....	28
10.5 日志输出示例.....	28
10.6 复核样本示例.....	29
十一、脚本实现说明.....	29
11.1 实现思路.....	29
11.2 主要脚本说明.....	30
11.3 运行方式说明.....	30
11.4 可扩展接口说明.....	30
十二、与后续产出的衔接说明.....	31

一、脚本设计背景与目标

为落实项目第二阶段“公开数据集批量获取与质量验证”中的“数据集批量下载与格式标准化”任务，需要对第一阶段筛选出的文本、图像、视频类公开数据集进行统一接入、格式转换、基础清洗、元数据标准化、许可分流及抽样复核准备。由于不同公开数据集在原始存储结构、文件格式、标签字段、命名规则及使用许可上存在明显差异，若直接用于后续质量验证和测试集构建，容易造成处理链路不统一、样本管理混乱、许可边界不清、标注复核难以落地以及后续场景适配成本上升。

因此，本脚本不仅承担格式转换与基础清洗功能，同时作为公开数据集进入基础候选池前的统一准入管道（ingestion + normalization + validation + compliance triage pipeline），负责完成以下工作：

对第一轮核心候选公开数据集进行批量接入、统一管理与原始归档；

将不同模态数据统一转换为项目要求的标准格式：文本为 JSONL、图像为 JPEG、视频为 MP4；

自动补充统一元数据字段，形成可支持后续质量验证、抽样复核、场景化筛选和测试集构建的数据基础；

执行基础质量校验，包括空白内容过滤、损坏文件过滤、低质量样本初筛、重复记录去除等；
执行内容风险预筛与许可合规分流，其中内容风险预筛仅用于识别需人工复核或需隔离管理的样本，不替代正式风控判定；

为第二阶段“标注质量抽样验证”提供抽样清单、复核回写接口与统计字段预留；

输出统一日志、统计摘要和审计信息，支撑后续《公开数据集质量验证报告》、标注准确率统计及基础数据集分析图表生成。

本脚本的定位是第二阶段的数据工程底座，其输出结果不直接等同于最终测试集，也不直接形成业务风控结论，而是为后续人工抽样复核、标注质量验证、字节场景适配、标准输入格式转换和有效性验证提供可复用的数据基础。

二、适用数据范围

本脚本面向当前已确定的第一轮核心候选公开数据集，后续可根据下载可行性、许可复核情况和处理进度进行扩展。

2.1 文本数据集

HC3

2.2 图像数据集

GenImage

FaceForensics++

2.3 视频数据集

DFDC

Celeb-DF

FaceForensics++

FakeAVCeleb

DeeperForensics-1.0

说明：

- 1.FaceForensics++涉及图像帧处理和视频处理场景，可根据实际下载内容和后续任务需求分别纳入图像或视频处理流程。
- 2.FaceForensics++同时覆盖图像帧样本与视频样本两类处理对象，文档中按潜在处理形态分别列入图像与视频范围，实际执行时以已获批下载内容和处理目标为准，不重复计量。
- 3.本脚本优先覆盖“可下载、可处理、可统一”的核心数据集，不对未完成下载或未完成许可复核的数据集强行纳入处理范围。

2.4 数据集获取与路径配置

数据集	获取方式	原始路径（脚本读取位置）	备注
HC3	Hugging Face 下载	01_raw_data/HC3/	使用 huggingface_hub 下载
GenImage	GitHub 仓库	01_raw_data/GenImage/	需手动 git clone 或下载 zip
DFDC	Kaggle 竞赛页	01_raw_data/DFDC/	需接受条款后下载，建议使用 Kaggle API，原数据授权页 deepfakedetectionchallenge.ai/license 已失效（重定向至 Meta.ai 产品页），商用授权原文不可得，Meta 官方联系入口 ai.meta.com/contact-us/ 亦已无法访问；Rules B.7.B 明确禁止向非参赛方再分发数据；双渠道失效，commercial_use 按 unknown 处理，redistribution=forbidden，在当前公开授权信息无法满足项目商用合规要求的情况下，暂不纳入后续授权追踪范围。
FaceForensics++	官网申请	01_raw_data/FaceForensics++/	官方数据库访问条款明确限定仅可用于 non-commercial research and educational purposes；第 6 条规定申请人如受雇于营利性商业实体，其雇主同样受该条款约束。故判定 commercial_use=forbidden、redistribution=restricted，写入

			02_processed/isolation/license/video/FaceForensics++/, 当前阶段不纳入候选池。代码仓库许可与数据访问条款应分开记录, 不应将代码仓库的 MIT 许可直接视为数据本体可商用。
Celeb-DF	GitHub 仓库	01_raw_data/Celeb-DF/	申请条款明确: 仅限非商业研究, 禁止复制、转售、再分发及发布任何片段或衍生数据; 需学术邮箱申请。当前记为 commercial_use=forbidden、redistribution=forbidden, 默认进入 02_processed/isolation/license/video/Celeb-DF/, 仅保留接入登记、许可审计和隔离留痕。
FakeAVCeleb	GitHub 仓库	01_raw_data/FakeAVCeleb/	仅限非商业研究与教育用途, 禁止复制、再现、发布、分发任何片段或衍生数据 (条款 7); 营利性机构雇主同样受约束 (条款 6); 需官方学术/机构邮箱填表申请; 当前记为 commercial_use=forbidden、redistribution=forbidden, 默认进入 02_processed/isolation/license/video/FakeAVCeleb/, 不纳入本批次候选池; 如后续许可状态更新, 可按数据集级复审机制处理。

补充说明:

纳入本脚本文档配置范围, 不等于自动纳入第二阶段基础候选池或第三阶段测试集构建范围。对于许可状态为 forbidden 或 unknown 的数据集, 脚本仅执行必要的接入登记、许可审计、隔离存放和日志留痕, 不进入主处理链路; 对于 commercial_use=restricted 的数据集, 仅在人工复核确认限制条款可满足后, 方可进入候选池参与后续质量验证与测试集构建。

三、脚本总体流程

本脚本采用模块化设计, 整体处理流程如下:

配置读取 → 数据接入/原始归档 → 格式识别 → 标准化转换 → 元数据生成 → 基础质量校验 → 去重处理 → 内容风险预筛 → 许可合规分流 → 抽样复核清单生成 → 日志记录 → 结果导出

各环节功能如下:

配置读取: 读取数据集名称、路径、许可信息、标签映射规则、清洗阈值、抽样参数、目标输出路径等配置项;

数据接入/原始归档: 对下载完成的数据集进行统一接入, 保留原始目录结构和原始文件作为回溯底稿;

格式识别: 识别原始样本所属模态及文件格式, 并检查是否满足可处理条件;

标准化转换: 执行文本转 JSONL、图像转 JPEG、视频转 MP4 等标准化处理;

元数据生成：为每条样本补充统一字段，包括数据 ID、来源数据集、原始样本 ID、标签、路径、许可状态、处理批次等；

基础质量校验：执行空白样本过滤、损坏文件过滤、低质量样本初筛、关键字段缺失检查等；

去重处理：执行同数据集内去重、跨数据集去重及必要的近重复检测预留；

内容风险预筛：对可能涉及色情、暴力等高风险内容的样本进行预筛标记与分流，仅用于风险提示、隔离管理和人工复核，不在本阶段直接作最终违规认定；

许可合规分流：根据样本所属数据集的许可状态和 commercial_use 字段进行物理分流；

抽样复核清单生成：按数据集、标签、模态等维度生成随机抽样样本清单，供第二阶段人工标注复核与标注准确率统计使用；

日志记录：记录转换成功、转换失败、过滤原因、隔离原因、异常信息及处理统计；

结果导出：输出标准化数据、样本级元数据、抽样复核清单、处理摘要、错误日志及统计报告；如提供人工复核回写文件，脚本还可继续执行复核结果合并、标签准确率统计和数据集级结论更新。

样本状态流转规则

为保证样本处理链路可追踪、可复核、可审计，脚本对每条样本设置统一状态字段 record_status。建议取值如下：

状态值	含义
ingested	已接入原始目录
normalized	已完成格式标准化转换
validated	已完成基础质量校验
candidate_ready	满足当前候选池准入条件
pending_review	需人工复核（含许可待确认、标签映射歧义、内容预筛低置信命中等）
isolated_license	因许可不明确或当前不满足准入条件而隔离
isolated_compliance	因内容风险预筛命中而隔离（高置信命中）
isolated_corrupted	因文件损坏、空白、不可解码等工程性问题而隔离
rejected	经人工复核确认不纳入当前候选流程
sampled_for_label_review	已进入人工标注抽样复核队列

重要说明：

record_status 仅描述工程流转状态，不与复核结论混用。

如需表达待许可复核、待内容复核等细分原因，应通过 review_status、isolation_reason、remark、content_risk_tags 等附加字段说明。

同一时点每条样本仅保留一个主 record_status 值。


如需支持数据集级质量结论，可另设 dataset_review_status 字段，建议取值为：pending / passed / failed_label_quality / failed_license / failed_integrity。

四、目录结构设计

4.1 整体目录结构

AIGC_standard_testset/

|




```

|   |—— processing_summary.json
|   |—— filter_reason_stats.csv
|   |—— license_distribution.csv
|   |—— dataset_level_report.csv
|   |—— quality_verification_report.md
|
|—— 05_logs/                                # 运行日志
|   |—— pipeline.log
|   |—— error.log
|   |—— warning.log
|
|—— 06_scripts/                             # 脚本与配置
|   |—— main.py
|   |—— cleaner.py
|   |—— metadata_builder.py
|   |—— ...
|   |—— config/
|       |—— datasets_config.json

```

4.2 各目录详细说明

01_raw_data/ —— 原始数据归档

项目	说明
存放内容	从 GitHub、Kaggle、Hugging Face 等平台下载的原始数据，不做任何修改
设计思路	保留原始数据作为“底稿”，如果处理出错可以重新来过，不用重新下载
命名规则	每个数据集单独一个文件夹，文件夹名与数据集名称一致

02_processed/ —— 处理后数据

本目录是经过标准化转换、基础清洗和分流处理后的样本存储根目录，是后续质量验证、人工复核和候选池构建的直接输入区域。不设置独立的 `normalized/` 目录，样本根据当前状态直接落入以下三类子目录：

(1) candidate_pool/ —— 候选池

项目	说明
存放内容	已通过基础质量校验，且当前许可状态满足准入条件的样本
准入条件	<code>commercial_use = allowed</code> 或 <code>restricted</code> 且 <code>restriction_cleared = true</code>
子目录	<code>text/</code> 、 <code>image/</code> 、 <code>video/</code>
命名规则	{数据集名称}_{6 位编号}.{格式}，如 <code>HC3_000001.jsonl</code>

(2) pending_review/ —— 待人工复核

项目	说明
----	----

存放内容	需要人工复核的样本：commercial_use = restricted（待确认限制条款）、标签映射歧义样本、内容预筛低置信命中样本
子目录	text/、image/、video/
命名规则	同上

(3) isolation/ —— 物理隔离区

项目	说明
存放内容	当前阶段不纳入候选池的样本，细分为三类
子目录	license/、compliance/、corrupted/，其下各含 text/、image/、video/

isolation/license/：commercial_use = forbidden 或 unknown 的样本，当前阶段不纳入候选池，如 GenImage、DFDC、FaceForensics++、Celeb-DF、FakeAVCeleb、DeeperForensics-1.0。

isolation/compliance/：内容风险预筛命中且需独立管理的样本（高置信命中）。

isolation/corrupted/：文件损坏、无法读取、不可解码等工程性无效样本。

03_metadata/ —— 元数据

项目	说明
存放内容	每个样本的“身份证信息”，包括来源、标签、生成模型、质量评分等
设计思路	元数据与数据内容分离存储，便于后续筛选、统计和标签映射
格式	JSONL 格式（每行一个 JSON 对象），方便逐行读取，仅存储路径引用，不存储原文/原图/原视频
主要文件	text_metadata.jsonl、image_metadata.jsonl、video_metadata.jsonl

04_reports/ —— 质量验证报告

项目	说明
存放内容	清洗前后的统计对比、标注准确率、错误日志等
设计思路	所有“结论性”输出集中存放，便于老师审阅

05_logs/ —— 运行日志

项目	说明
存放内容	脚本运行时的详细信息，包括成功、失败、警告等
设计思路	日志与报告分离，日志用于调试，报告用于交付

06_scripts/ —— 脚本代码

项目	说明
----	----

存放内容	所有 Python 脚本和配置文件
设计思路	代码与数据分离，便于版本管理和复用

4.3 状态与目录映射关系

commercial_use	restriction_cleared	输出目录
allowed	—	candidate_pool/{modal}/
restricted	false	pending_review/{modal}/
restricted	true	candidate_pool/{modal}/
forbidden	—	isolation/license/{modal}/
unknown	—	isolation/license/{modal}/

说明：内容风险预筛命中的样本优先按合规隔离规则处理，不受上表约束。高置信命中进入 isolation/compliance/，低置信命中进入 pending_review/。

五、数据集配置说明

5.1 配置文件作用

脚本不将数据集信息硬编码在代码中，而是通过独立的配置文件 datasets_config.json 管理。这样做的好处是：

新增数据集时只需修改配置文件，无需改动脚本代码；
不同数据集的清洗规则、路径、标签映射可以独立调整；
便于维护和版本管理。

配置文件放在 06_scripts/config/datasets_config.json

5.2 datasets_config.json 示例

HC3:

```

type: text
category: text
source: huggingface
source_path: Hello-SimpleAI/HC3
download_method: huggingface_hub
raw_path: 01_raw_data/HC3/
output_path: 02_processed/pending_review/text/HC3/
license_type: CC-BY-SA-4.0
license_source: https://huggingface.co/datasets/Hello-SimpleAI/HC3
commercial_use: restricted
redistribution: restricted
derivative_obligation: share_alike
pool_assignment: pending_review

```

review_status: pending
restriction_cleared: false
cleaning_rules:
 min_text_length_zh: 5
 min_text_tokens_en: 3
 remove_blank_text: true
 remove_duplicate_text: true
label_mapping:
 human: human_written
 chatgpt: ai_generated

GenImage:

type: image
category: image
source: github
source_path: <https://github.com/.../GenImage>
download_method: git_clone
raw_path: 01_raw_data/GenImage/
output_path: 02_processed/isolation/license/image/GenImage/
license_type: CC-BY-NC-SA-4.0 + dataset_terms
commercial_use: forbidden
redistribution: restricted
derivative_obligation: non_commercial+share_alike
pool_assignment: isolation
isolation_reason: non-commercial only
review_status: rejected
cleaning_rules:
 min_short_edge: 224
 remove_corrupted: true
 remove_near_solid: true

DFDC:

type: video
category: video
source: kaggle
source_path: deepfake-detection-challenge
download_method: kaggle_api
raw_path: 01_raw_data/DFDC/
output_path: 02_processed/isolation/license/video/DFDC/
license_type: kaggle_competition_rules
license_source: <https://deepfakedetectionchallenge.ai/license>
commercial_use: unknown
redistribution: forbidden
pool_assignment: isolation

isolation_reason: commercial rights not verifiable from currently accessible official channels
review_status: pending
cleaning_rules:
 min_duration: 5
 max_duration: 20
 target_duration: 15
 target_fps: 30
 sample_ratio: 0.3

FaceForensics++:

type: image_video
category: video
source: official_request
source_path: <https://github.com/ondyari/FaceForensics>
download_method: official_request
raw_path: 01_raw_data/FaceForensics++/
output_path: 02_processed/isolation/license/video/FaceForensics++/
code_license: MIT
data_license: official_access_terms
license_source: official access request terms
commercial_use: forbidden
redistribution: restricted
derivative_obligation: citation_required
pool_assignment: isolation
isolation_reason: data access terms limit use to non-commercial research and educational purposes
review_status: rejected
restriction_cleared: false

Celeb-DF:

type: video
category: video
source: form_application
download_method: form_application
raw_path: 01_raw_data/Celeb-DF/
output_path: 02_processed/isolation/license/video/Celeb-DF/
license_type: custom_research_only
commercial_use: forbidden
redistribution: forbidden
requires_academic_email: true
contact: deepfakeforensics@gmail.com
pool_assignment: isolation
isolation_reason: non-commercial research only + redistribution forbidden
review_status: rejected

FakeAVCeleb:

type: multimodal
category: video
source: form_application
download_method: form_application
raw_path: 01_raw_data/FakeAVCeleb/
output_path: 02_processed/isolation/license/video/FakeAVCeleb/
license_type: custom_research_only
commercial_use: forbidden
redistribution: forbidden
requires_academic_email: true
contact_institution: Sungkyunkwan University
pool_assignment: isolation
isolation_reason: non-commercial only + redistribution forbidden
review_status: rejected

DeeperForensics-1.0:

type: video
category: video
source: github
source_path: <https://github.com/EndlessSora/DeeperForensics-1.0>
download_method: manual_eula_application
raw_path: 01_raw_data/DeeperForensics-1.0/
output_path: 02_processed/isolation/license/video/DeeperForensics-1.0/
code_license: MIT
data_license: non-commercial research EULA
license_source: <https://github.com/EndlessSora/DeeperForensics-1.0>
commercial_use: forbidden
redistribution: forbidden
pool_assignment: isolation
isolation_reason: dataset use limited to non-commercial research purposes
review_status: rejected

5.3 各数据集配置参数说明

参数	类型	说明
type	string	数据类型：text / image / video / image_video / multimodal
category	string	业务分类：text / image / video
source	string	来源平台：huggingface / github / kaggle /

		official_request / form_application
source_path	string	来源平台中的路径或链接
download_method	string	下载方式: huggingface_hub / git_clone / kaggle_api / official_request / form_application / manual_eula_application
raw_path	string	原始数据存放路径
output_path	string	处理结果输出路径
license_type	string	许可证类型或授权结构说明
license_source	string	许可证页面、README、申请表或授权说明链接
commercial_use	string	商用许可状态: allowed / restricted / forbidden / unknown
redistribution	string	再分发许可状态: allowed / restricted / forbidden / unknown
derivative_obligation	string	衍生作品义务: none / attribution / share_alike / non_commercial / unknown
pool_assignment	string	测试集构建范围去向: passed / pending_review / isolation
isolation_reason	string	隔离原因说明
review_status	string	许可复核状态: pending / cleared / rejected / confirmed_ineligible
cleaning_rules	object	清洗规则参数
label_mapping	object	标签映射规则
processing_mode	string	处理模式, 如 frame_extract / direct_convert

cleaning_rules 参数说明

参数	适用类型	说明
min_length	text	文本最小长度 (字符数)
max_length	text	文本最大长度 (字符数)
remove_academic	text	是否剔除学术性过强的样本
remove_duplicates	text	是否去除完全重复的文本
remove_sensitive_domains	text	需要剔除的敏感领域 (如 medical, finance)
min_resolution	image	图像最小分辨率 [宽度, 高度]
remove_corrupted	image	是否剔除损坏图像

deduplicate	image	是否去重（基于文件哈希）
remove_abstract	image	是否剔除抽象/实验性图像
min_duration	video	视频最小时长（秒）
max_duration	video	视频最大时长（秒）
target_duration	video	截取的目标时长（秒）
target_fps	video	目标帧率
sample_ratio	video	分层抽样比例（用于超大规模数据集）
min_face_size	image_video	最小人脸尺寸（像素）
frame_interval	image_video	抽帧间隔（每隔多少帧提取一帧）
remove_blur	image_video	是否剔除模糊帧
sync_check	multimodal	是否检查音视频同步

六、核心模块设计

本脚本采用分模块处理方式，以提高后续维护、扩展和复用效率。

6.1 数据集配置读取模块

负责读取 `datasets_config.json` 中的数据集名称、数据类型、原始路径、目标路径和标签映射规则。该模块的作用是将不同数据集的处理规则外置，避免将数据集特定逻辑硬编码在主控脚本中。

6.2 数据导入与原始文件归档模块

负责对已下载数据集进行路径接入和原始文件归档，确保后续处理时既能访问原始数据，也能保留必要的回溯依据。该模块不改变原始数据内容，重点是建立统一入口。

6.3 文本转换模块

负责读取 CSV、JSON、TXT 等文本数据，将其转换为统一 JSONL 格式，并对原始标签进行标准化映射。处理过程中同步补充数据 ID、来源数据集、内容类型等字段。

6.4 图像转换模块

负责识别 PNG、JPG、JPEG、WEBP、BMP 等常见图像格式，并统一转换为 JPEG 格式。同时完成统一命名、分辨率检查和基本图像质量初筛。

6.5 视频转换模块

负责识别 MP4、AVI、MOV、MKV、WEBM 等常见视频格式，并调用 FFmpeg 统一转为 MP4。处理过程中提取时长、分辨率等信息，并完成过短视频、异常视频的初步过滤。

6.6 元数据生成模块

负责统一生成样本级元数据记录，确保文本、图像、视频三类数据可在同一套字段体系下管理。该模块是后续质量验证报告、数据池构建和统计分析的基础。

6.7 基础数据清洗模块

负责执行基础过滤与初步去重，包括：

空白文本过滤

损坏图像/视频过滤

低分辨率图像过滤

过短视频过滤

缺失关键字段的样本过滤

重复记录去除

6.8 日志与统计输出模块

负责输出运行日志、错误日志和处理摘要，记录转换失败、标签缺失、文件损坏等异常情况，便于后续复查和人工补充处理。

6.9 抽样复核与标注准确率统计模块

负责根据配置参数对各数据集执行随机抽样或分层抽样，生成供人工复核使用的样本清单，并在人工复核结果回写后，自动计算各数据集原始标签准确率、常见错误类型和是否达到第二阶段准入阈值。

该模块建议输出以下结果：

1.review_sample_list.csv/jsonl：复核样本清单；

2.review_result_merged.csv：原始标签与人工复核标签对比结果；

3.label_accuracy_report.csv：各数据集标注准确率统计；

4.label_error_type_stats.csv：常见标注错误类型分布；

5.数据集级结论字段 dataset_review_status，用于标识 passed / failed_label_quality。

七、统一格式与字段规则

7.1 统一存储格式规则

根据项目第二阶段处理要求，三类数据统一采用如下标准化输出格式：

文本：统一为 JSONL

图像：统一为 JPEG

视频：统一为 MP4

该规则有利于后续批量读取、统一处理链路和统计分析，也便于第三阶段继续转换为适配下游模型或评测流程的标准输入结构。

需要说明的是，标准化输出仅用于统一处理与管理，不替代原始数据归档。原始文件始终保

留在 01_raw_data/ 作为回溯底稿，必要时可基于原始文件重新生成更适配的标准化结果。

为减少标准化过程中的信息损失，建议额外记录以下元数据：

文本：原始文件类型、编码方式、原始字段结构；

图像：原始格式、宽高、色彩模式、是否存在透明通道；

视频：原始封装格式、编码器、帧率、时长、分辨率、音轨情况。

如图像从 PNG/WEBP 转为 JPEG，应记录原始格式并保留透明通道处理方式；如视频转码失败，不应覆盖原文件，而应记录失败原因并转入异常日志或 isolation/corrupted/。

7.2 统一命名规则

为避免不同数据集原始命名规则不一致导致冲突，脚本统一采用以下命名方式：

数据集名称_六位编号

示例：

HC3_000001

GenImage_000235

DFDC_001024

图像和视频输出文件可进一步扩展为：

GenImage_000235.jpg

DFDC_001024.mp4

7.3 统一元数据字段设计

为保证不同模态、不同来源数据集在同一套处理链路中可统一管理，元数据字段建议分为基础字段、质量字段、合规字段、审计字段四类。

（1）基础字段

字段名	含义
data_id	样本唯一标识
content_type	内容类型：text / image / video
source_dataset	来源数据集名称
source_split	原始划分：train / val / test / unknown
source_sample_id	原始数据集中的样本 ID
source_uri	原始文件路径、URL 或来源标识
raw_label	原始标签
standard_label	标准化后的标签
label_mapping_rule	标签映射依据
label_mapping_confidence	映射置信度：high / medium / low
generation_model	生成模型信息，如可获得则填写
manipulation_type	操作类型，如 deepfake / reenactment / face_swap

（2）质量字段

字段名	含义
quality_status	质量状态：passed / filtered / pending_review
quality_reasons	质量处理原因，如 blank_text / low_resolution / corrupted_file

quality_score	基础质量评分，可选
dedup_group_id	去重分组 ID
file_hash_sha256	文件哈希值
perceptual_hash	图像/关键帧感知哈希，可选
duration_sec	视频时长（视频适用）
fps	帧率（视频适用）
width	宽度
height	高度
has_audio	是否包含音轨（视频适用）
original_format	原始格式
converted_format	转换后格式
conversion_applied	是否执行格式转换

（3）合规字段

字段名	含义
content_compliance_status	内容风险预筛状态：clean / flagged / pending_review
content_risk_tags	内容风险标签，如 pornography / violence / hateful / self_harm
license_type	数据许可类型
license_source	许可依据来源
commercial_use	商用许可状态：allowed / restricted / forbidden / unknown
redistribution	再分发状态：allowed / restricted / forbidden / unknown
derivative_obligation	衍生作品义务
isolation_reason	隔离原因
isolation_date	隔离日期
restriction_cleared	restricted 样本是否已完成许可复核

（4）审计字段

字段名	含义
record_status	工程流转状态，仅描述样本当前所处的物理/流程阶段。可选值：ingested、normalized、isolated_corrupted、isolated_license、isolated_compliance、pending_review、candidate_ready。不与复核结论混用。
ingest_batch_id	接入批次号
ingest_time	入库时间
processor_version	脚本版本号
validation_time	质量校验时间
review_status	人工复核状态，仅描述复核结论。可选值：pending、cleared、rejected、confirmed_ineligible。
review_round	复核轮次
reviewer	复核人
review_date	复核日期
review_decision_reason	复核结论说明

remark	备注信息
--------	------

(5) 复核字段

字段名	含义
sampled_for_review	是否被抽中进入人工复核
review_round	复核轮次
review_label	人工复核标签
review_result	consistent / corrected / disputed
review_date	复核日期
label_error_type	标注错误类型，如 wrong_class / ambiguous_definition / source_noise / mapping_error

重要约束：record_status 不得包含复核结论含义（如禁止使用 pending_license_review 作为 record_status）。如需表达“待许可复核”，应使用 record_status = pending_review 且 review_status = pending，并在 isolation_reason 或 remark 中说明原因。

7.4 标签标准化规则

不同数据集原始标签体系不完全一致，脚本统一映射为项目基础标签体系，以便进行跨数据集管理和后续质量验证。映射时应同时保留原始标签 raw_label，并记录映射依据和映射置信度。

示例映射如下：

文本：human → human_written, chatgpt → ai_generated

图像：real → real, fake → synthetic

视频：real → real, fake → deepfake

如原始标签能够与标准标签一一对应，则 label_mapping_confidence=high；

如存在语义歧义或跨数据集标签定义不完全一致，则标记为 medium 或 low；

如无法可靠映射，不应强行归类，应写入 pending_review 并保留原始标签以待人工确认。为避免“生成方式”和“业务风险”混淆，建议第二阶段仅完成基础标签标准化，不在本阶段直接输出结论性的业务风险等级。后续如需适配字节风控分类标准，可在第三阶段重新标注时完成扩展映射。

八、数据清洗规则

本脚本中的清洗定位为**基础清洗和工程预处理**，重点解决“能否进入后续验证环节”的问题，而不直接替代正式质量验证报告。

8.1 去重规则

去重分为三个层级执行：

数据集内去重：去除同一公开数据集内部的完全重复样本；

跨数据集去重：识别不同公开数据集之间的完全重复样本，并为近重复检测预留接口；

后续数据划分去重预留：为第三阶段训练/验证/测试隔离提供去重基础，降低样本泄漏风险。

第一版建议优先执行确定性去重，近重复检测作为可选模块，不作为主流程硬门槛。建议策

略如下：

文本：

完全重复：基于规范化文本内容计算 SHA256；

近重复：预留 simhash 或 embedding 相似度接口，仅作辅助提示。

图像：

完全重复：基于文件哈希去重；

感知近重复：预留 pHash 检测，对相似度高于阈值的样本标记为 pending_review。

视频：

完全重复：基于文件哈希去重；

近重复：预留“关键帧哈希 + 时长接近 + 分辨率接近”的组合检测，仅作候选提示。

当多个重复样本中需要保留一条时，建议按以下优先级保留：

元数据更完整者；

质量更高者；

许可状态更明确者；

来源说明更清晰、可追溯性更强者。

对于去重结果，建议在元数据中保留 dedup_status、duplicate_group_id、dedup_reason 等字段，以支持后续复查和召回。

8.2 无效样本过滤规则

以下样本可直接判定为工程性无效样本，不进入后续主流程：

空白文本、仅标点文本、仅 URL 文本、仅 emoji 文本；

文本编码异常、乱码且无法修复的样本；

损坏图像、无法读取图像、无法解码图像；

损坏视频、无法解码视频、关键帧提取失败且无法修复的视频；

缺失关键标签且无法映射的样本；

元数据关键字段严重缺失且无法补齐的样本。

上述样本应写入错误日志，并在必要时移入 isolation/corrupted/ 或标记为 rejected。

8.3 低质量样本过滤规则

低质量样本过滤采用“全局默认规则 + 数据集级覆盖配置”的方式执行。全局默认规则用于提供统一基线，若某数据集在配置文件中提供更严格或更适配的阈值，则以数据集级配置为准。

默认建议如下：

文本

中文有效字符数 < 5：标记为低信息量；

英文 token 数 < 3：标记为低信息量；

重复字符占比超过 80%：标记为疑似垃圾文本；

明显乱码且无法修复：直接过滤。

说明：上述长度阈值默认用于“低信息量提示”，不必一律直接删除；是否作为硬过滤条件，应结合具体任务目标配置。

图像

图像短边 < 224 px：标记为低分辨率；

宽高比极端异常（如 >10:1）：标记 pending_review；

纯色图、近纯色图、严重模糊图：标记为低质量；

无法解码图像：直接过滤。

视频

视频时长 < 3s：按全局默认规则视为无效样本；

视频短边 < 224 px：标记为低分辨率；

黑屏、长时间静帧、帧率异常、关键帧提取失败：标记 pending_review 或直接过滤；

无音轨视频：不直接过滤，但记录 has_audio=false。

如数据集配置中存在如 min_duration=5 等更严格阈值，则以该数据集配置覆盖全局默认规则。第二阶段的目标是构建基础候选数据池，因此低质量过滤应优先聚焦工程可用性和基本判别意义，不宜过早引入与具体业务场景强绑定的偏好性筛选条件。

8.4 高风险内容预筛与隔离机制

本脚本中的内容相关处理仅定位于“风险预筛、流转控制和人工复核分流”，不替代正式内容审核、违规认定或平台处罚决策。

为降低高风险样本在后续流转中的误用风险，建议采用如下处理方式：

技术实现约定：

当前版本的内容预筛采用关键词匹配 + 开源轻量分类模型（如 CLIP-based NSFW detector）的双层机制：

关键词命中：直接视为高置信（置信度 ≥ 0.95 ）；

模型输出：置信度 ≥ 0.90 视为高置信；0.70~0.89 视为低置信；< 0.70 视为未命中。

示例说明：

高置信命中：record_status = "isolated_compliance"，review_status = "pending"，content_risk_tags = ["pornography_high_conf"]

低置信命中：record_status = "pending_review"，review_status = "pending"，content_risk_tags = ["violence_low_conf"]，remark = "内容预筛低置信命中，需人工复核"

处置边界说明如下：

1. 第二阶段脚本仅负责工程预筛、隔离管理和流转控制；
2. 预筛结果仅用于风险提示和人工复核排序，不作为最终政策判断依据；
3. 如需形成正式风控标签，应在后续独立审核或重标注流程中完成。

为避免术语产生误解，建议统一使用 risk_precheck_hit、isolated_compliance、pending_review 等工程化表达，不使用具有终局判断含义的措辞。

8.5 许可合规隔离规则

本节仅处理许可与使用边界问题，依据元数据中的 commercial_use、redistribution、license_type、license_source 等字段执行工程分流。该分流结果用于当前项目处理决策，不替代正式法律意见。

许可分流遵循以下规则：

commercial_use=forbidden 的样本：直接进入 isolation/license/，当前阶段不纳入候选池；

commercial_use=unknown 的样本：在缺乏可审计授权依据前，默认进入 isolation/license/，当前阶段不纳入候选池；

commercial_use=restricted 的样本：不得直接进入 candidate_pool/，应先进入 pending_review/；仅在人工复核确认限制条款可满足，且 restriction_cleared=true 后，方可

进入 candidate_pool/;

当数据集自定义条款与通用开源许可证同时存在时，以对数据本体限制更强者为准；

已进入候选流程的数据集，如后续许可证说明、访问条款或使用边界发生变化，应支持按 source_dataset + ingest_batch_id 进行批量复审与必要召回。

当前项目建议处理策略如下：

HC3：基于 CC-BY-SA-4.0，商业使用并非绝对禁止，但存在署名与相同方式共享义务，暂记为 commercial_use=restricted、redistribution=restricted。默认进入 pending_review/，待人工确认使用场景能够满足相关义务后再决定是否进入候选池。

GenImage：条款明确包含非商业限制，记为 commercial_use=forbidden，进入 isolation/license/image/，当前阶段不纳入候选池。

Celeb-DF：申请条款明确仅限非商业研究，且禁止再分发，记为 commercial_use=forbidden、redistribution=forbidden，进入 isolation/license/video/。

FaceForensics++：代码仓库许可与数据访问条款分开处理。代码部分可单独记录为 code_license=MIT，数据本体使用条款记为 data_license=official access terms。由于数据条款明确限制为非商业研究和教育用途，故数据样本记为 commercial_use=forbidden，进入 isolation/license/video/。

FakeAVCeleb：申请条款明确仅限非商业研究与教育用途，禁止复制、发布、分发样本或衍生数据，记为 commercial_use=forbidden、redistribution=forbidden，进入 isolation/license/video/。

DFDC：当前可访问渠道下无法获得可审计的明确商业使用授权依据，且竞赛规则对再分发存在限制，暂记为 commercial_use=unknown、redistribution=forbidden，进入 isolation/license/video/。当前处理结论为“默认隔离、待授权依据补充后复审”，不表述为最终法律定性。

DeeperForensics-1.0：公开说明显示数据本体限于非商业研究用途，代码许可与数据许可分开处理。数据样本记为 commercial_use=forbidden，进入 isolation/license/video/。

隔离区样本不参与本轮候选池统计与后续测试集构建；如后续获得明确、可审计、可追溯的授权依据，可按数据集级复审机制重新处理。

对涉及人脸、声音等生物特征信息的数据集，除许可证审查外，还应在接入登记中增加敏感属性标记，并在人工复核或模型验证流程中遵循最小访问、专人审批和用途限定原则。

8.6 统计输出要求

脚本运行结束后，建议自动输出以下统计文件，用于支撑第二阶段质量验证报告撰写：

processing_summary.json：总样本数、转换成功数、过滤数、隔离数、待复核数、候选池准入数；

filter_reason_stats.csv：各类过滤原因统计；

license_distribution.csv：各数据集许可状态分布；

label_mapping_stats.csv：标签映射结果统计；

dataset_level_report.csv：按数据集统计原始数量、保留数量、过滤率、隔离率、待复核比例。

8.7 标注质量抽样验证规则

为落实第二阶段“标注质量抽样验证”任务，脚本应支持对每个进入候选流程的数据集自动生成抽样复核清单，并在人工复核结果回写后完成准确率统计与数据集级处置。

建议默认规则如下：

抽样范围

对每个进入候选流程的数据集执行抽样复核；

默认抽样量可设为： $\max(50, \min(200, \text{ceil}(5\% * \text{dataset_size})))$ ；

如数据集样本量较小，且某一标签样本数低于默认抽样下限，可对该标签全量复核。

抽样方式

优先采用按标签分层抽样；

如涉及多模态、来源 split 或多个子来源，可在标签分层基础上叠加按模态、来源 split 分层；

抽样配置应写入报告，便于后续复现。

复核内容

原始标签是否准确；

标签映射是否正确；

样本内容是否可判；

是否存在来源噪声、语义歧义或映射错误。

准确率计算

以人工复核标签为参照，统计原始标签一致率；

若数据集级标签准确率 $< 90\%$ ，则记为 `dataset_review_status=failed_label_quality`，默认不纳入后续候选池保留范围；

若达到阈值，则记为 `dataset_review_status=passed`。

复核结果留痕

应记录复核样本 ID、原始标签、复核标签、错误类型、复核人、复核时间和结论说明；

建议输出：

`review_sample_list.csv/jsonl`

`review_result_merged.csv`

`label_accuracy_report.csv`

`label_error_type_stats.csv`

第二阶段抽样复核的结论用于决定数据集是否保留在基础候选流程中；如第三阶段需要按内部业务分类标准重标注，应在此基础上另行开展，不与本阶段基础标签验证混用。

九、异常处理机制

由于公开数据集来源多样、文件结构复杂、格式差异较大，脚本需要具备基础异常处理能力，避免单个文件或单个数据集报错导致整个流程中断。

9.1 主要异常类型

下载文件缺失或路径错误

文本文件编码异常

图像文件损坏或解码失败

视频转码失败

标签字段缺失或标签值不在映射表内

元数据字段冲突

输出目录不存在或写入失败

9.2 处理策略

对单个文件级异常采用 try-except 捕获，记录日志后继续处理后续样本；
对数据集级异常记录错误日志，并在主流程中继续处理其他数据集；
对标签缺失但可补录的样本，可标记为 pending_review；
对转换失败样本统一记录至错误日志，供后续人工复核；
对关键路径和输出目录在脚本启动时统一创建，减少因目录不存在导致的写入错误。

9.3 审计与复核留痕要求

为保证脚本输出结果可回溯、可复核、可审计，异常处理之外还应对关键操作留存审计信息。
建议至少记录以下内容：

- 1.处理批次信息：包括 ingest_batch_id、处理时间、脚本版本号、配置文件版本；
- 2.样本级处理结果：包括格式转换结果、质量过滤原因、去重结果、隔离原因、当前状态；
- 3.人工复核记录：包括复核轮次、复核人、复核日期、复核结论、结论依据；
- 4.许可复核记录：包括许可来源、复核状态、限制条款摘要、是否允许进入候选池或继续后续流程；
- 5.异常日志：包括错误样本路径、异常类型、异常原因、是否重试、最终处置结果。

对 commercial_use=restricted、commercial_use=unknown、内容风险预筛命中的样本，建议进入人工复核流程或隔离复审流程，并保留处理依据和责任留痕。如复核意见冲突，可记录 review_conflict_flag=true 并升级处理。所有复核操作均应附带原因说明，以支撑后续质量验证报告和项目交付审阅。

操作过程中仅保留完成质量验证、抽样复核和后续测试集构建所必需的字段，避免无必要保留可能涉及个人信息或授权边界不清的冗余字段。

十、标准化输出示例

说明：本章示例为脚本预期输出格式的示意，具体数值（如 data_id、文件大小、样本数量等）以实际运行结果为准。这一部分用于展示脚本处理后的“结果长什么样”，增强文档的交付感和可执行性。

10.1 文本输出示例

10.1.1 文本样本元数据示例

1.HC3 许可待复核 示例

```
{
  "data_id": "HC3_000001_a3f2c8e1",
  "content_type": "text",
  "source_dataset": "HC3",
  "source_split": "train",
  "source_sample_id": "0",
  "source_uri": "01_raw_data/HC3/train.json",
  "raw_label": "chatgpt",
```

```

"standard_label": "ai_generated",
"label_mapping_rule": "chatgpt->ai_generated",
"label_mapping_confidence": "high",
"generation_model": "ChatGPT",
"quality_status": "passed",
"quality_reasons": [],
"quality_score": 0.95,
"file_hash_sha256": "xxx",
"license_type": "CC-BY-SA-4.0",
"license_source": "https://huggingface.co/datasets/Hello-SimpleAI/HC3",
"commercial_use": "restricted",
"redistribution": "restricted",
"derivative_obligation": "share_alike",
"restriction_cleared": false,
"content_compliance_status": "clean",
"content_risk_tags": [],
"sampld_for_review": false,
"record_status": "pending_review",
"review_status": "pending"
}

```

2. HC3 已进入抽样复核队列

```

{
  "data_id": "HC3_000001_a3f2c8e1",
  "content_type": "text",
  "source_dataset": "HC3",
  "source_split": "train",
  "source_sample_id": "0",
  "source_uri": "01_raw_data/HC3/train.json",
  "raw_label": "chatgpt",
  "standard_label": "ai_generated",
  "label_mapping_rule": "chatgpt->ai_generated",
  "label_mapping_confidence": "high",
  "generation_model": "ChatGPT",
  "quality_status": "passed",
  "quality_reasons": [],
  "quality_score": 0.95,
  "file_hash_sha256": "xxx",
  "license_type": "CC-BY-SA-4.0",
  "license_source": "https://huggingface.co/datasets/Hello-SimpleAI/HC3",
  "commercial_use": "restricted",
  "redistribution": "restricted",
  "derivative_obligation": "share_alike",
  "restriction_cleared": false,
  "content_compliance_status": "clean",

```

```

    "content_risk_tags": [],
    "sampled_for_review": true,
    "review_status": "pending",
    "record_status": "sampled_for_label_review"
}

```

10.1.2 具体示例

原始样本示意：HC3 原始 JSON 格式

```

json
{
  "id": "0",
  "question": "什么是人工智能？ ",
  "human_answer": "人工智能是研究使计算机模拟人类智能的学科。",
  "chatgpt_answer": "人工智能（AI）是计算机科学的一个分支，旨在创建能够执行通常需要人类智能的任务的系统。",
  "source": "百科问答"
}

```

转换后 JSONL 示例：

```

Json
{"data_id": "HC3_000001_a3f2c8e1", "content_type": "text", "source_dataset": "HC3",
"converted_path": "02_processed/pending_review/text/HC3/HC3_000001.jsonl", "content": "
什么是人工智能？ ", "generation_model": "human", "original_label": "human", "label":
"human_written", "license": "CC-BY-SA-4.0", "commercial_use": "restricted", "restriction_note":
"衍生作品须以相同 CC-BY-SA-4.0 许可证发布", "restriction_cleared": false, "redistribution":
"allowed", "split": "", "format": "jsonl", "risk_level": "unknown", "quality_status": "passed",
"processing_log": "cleaned,length_filtered", "remark": "CC-BY-SA-4.0 restricted, 人工复核 SA
条款满足后置 restriction_cleared=true 方可进入商用测试集构建范围"}

```

```

{"data_id": "HC3_000002_b4e3d9f2", "content_type": "text", "source_dataset": "HC3",
"converted_path": "02_processed/pending_review/text/HC3/HC3_000002.jsonl", "content": "
人工智能（AI）是计算机科学的一个分支，旨在创建能够执行通常需要人类智能的任务的系
统。", "generation_model": "ChatGPT", "original_label": "chatgpt", "label": "ai_generated",
"license": "CC-BY-SA-4.0", "commercial_use": "restricted", "restriction_note": "衍生作品须以
相同 CC-BY-SA-4.0 许可证发布", "restriction_cleared": false, "redistribution": "allowed", "split":
"", "format": "jsonl", "risk_level": "unknown", "quality_status": "passed", "processing_log":
"cleaned,length_filtered", "remark": "CC-BY-SA-4.0 restricted, 人工复核 SA 条款满足后置
restriction_cleared=true 方可进入商用测试集构建范围"}

```

10.2 图像输出示例

GenImage 许可为 CC-BY-NC-SA 4.0（非商业），commercial_use 标 forbidden，故 converted_path 走隔离目录 02_processed/isolation/，不进商用测试集构建范围。

转换后 JSONL 示例：

```

{
  "data_id": "GenImage_000235_f81c2a7b",

```

```

"content_type": "image",
"record_status": "isolated",
"source_dataset": "GenImage",
"source_sample_id": "img_000235",
"source_uri": "01_raw_data/GenImage/train/fake/img_000235.png",
"raw_label": "fake",
"standard_label": "synthetic",
"label_mapping_rule": "fake->synthetic",
"label_mapping_confidence": "high",
"quality_status": "passed",
"file_hash_sha256": "xxx",
"width": 1024,
"height": 1024,
"original_format": "png",
"converted_format": "jpeg",
"conversion_applied": true,
"license_type": "CC-BY-NC-SA-4.0 + dataset_terms",
"commercial_use": "forbidden",
"redistribution": "restricted",
"derivative_obligation": "non_commercial+share_alike",
"isolation_reason": "non-commercial only",
"review_status": "confirmed_ineligible",
"ingest_batch_id": "20260601_batch_01",
"processor_version": "v1.2.0"

```

10.3 视频输出示例

DFDC 在当前可访问渠道下无法获得可审计的明确商业使用授权依据，且竞赛规则对再分发存在限制，因此在本项目当前阶段记为 commercial_use=unknown、redistribution=forbidden。对应处理路径为 02_processed/isolation/license/video/DFDC/，不纳入本批次候选池。此处仅作视频模态输出格式示意，不表示对其许可性质作最终法律定性。

JSON 示例：

```

{
  "data_id": "DFDC_001024_f9b2a6c3",
  "content_type": "video",
  "source_dataset": "DFDC",
  "source_path": "01_raw_data/DFDC/part_12/aagfhgtpmv.mp4",
  "converted_path": "02_processed/isolation/license/video/DFDC/DFDC_001024.mp4",
  "raw_label": "fake",
  "standard_label": "ai_generated",
  "manipulation_type": "face_swap",
  "format": "mp4",
  "license_type": "kaggle_competition_rules",
  "commercial_use": "unknown",

```

```

    "redistribution": "forbidden",
    "review_status": "pending",
    "isolation_reason": "commercial rights not verifiable from currently accessible official
channels",
    "record_status": "isolated_license"
}

```

10.4 元数据汇总文件示例

脚本执行完成后，可生成统一的元数据汇总文件 03_metadata/all_metadata.jsonl，用于合并存放多数据集样本级元数据，便于后续批量读取、统计分析和抽样复核追踪。将所有数据集的元数据合并到一个文件中，便于后续批量读取和统计分析

json:

```

{"data_id": "HC3_000001_a3f2c8e1", "content_type": "text", "content_path":
"02_processed/pending_review/text/HC3/HC3_000001.jsonl", "source_dataset": "HC3",
"standard_label": "human_written"}
{"data_id": "HC3_000002_b4e3d9f2", "content_type": "text", "content_path":
"02_processed/pending_review/text/HC3/HC3_000002.jsonl", "source_dataset": "HC3",
"standard_label": "ai_generated"}
{"data_id": "GenImage_000001_c7d4e5f6", "content_type": "image", "content_path":
"02_processed/isolation/license/image/GenImage/GenImage_000001.jpg", "source_dataset":
"GenImage", "standard_label": "synthetic"}
{"data_id": "DFDC_000001_d8e5f6g7", "content_type": "video", "content_path":
"02_processed/isolation/license/video/DFDC/DFDC_000001.mp4", "source_dataset": "DFDC",
"standard_label": "deepfake"}

```

设计说明：元数据文件仅存储路径引用，不存储原文/原图/原视频，避免文件膨胀，符合工程最佳实践。

10.5 日志输出示例

```

2026-06-01 10:00:01 - INFO - 开始处理批次: 20260601_batch_01
2026-06-01 10:00:02 - INFO - 开始处理数据集: HC3
2026-06-01 10:00:05 - INFO - HC3 原始数据加载完成: 25000 条
2026-06-01 10:00:08 - INFO - HC3 格式标准化完成: 25000 条
2026-06-01 10:00:10 - INFO - HC3 基础清洗后保留: 18500 条
2026-06-01 10:00:11 - INFO - HC3 restricted 样本写入 pending_review: 18500 条
2026-06-01 10:00:15 - INFO - 开始处理数据集: GenImage
2026-06-01 10:00:18 - INFO - GenImage 许可状态: forbidden, 写入
isolation/license/image/GenImage/
2026-06-01 10:00:20 - WARNING - 标签映射失败: HC3/raw/entry_777777, 原始标签:
unknown, 已标记为 pending_review
2026-06-01 10:00:25 - ERROR - 文件转换失败: GenImage/raw/sample_999999.png, 原因:
文件损坏无法解码
2026-06-01 10:00:28 - INFO - 批次处理完成: 总样本 875000, passed 0, pending_review
18500, isolated 856500

```

10.6 复核样本示例

(1)

```
{
  "data_id": "HC3_000245_b7e1d2c9",
  "content_type": "text",
  "source_dataset": "HC3",
  "raw_label": "chatgpt",
  "standard_label": "ai_generated",
  "sampled_for_review": true,
  "review_round": 1,
  "review_label": "ai_generated",
  "review_result": "consistent",
  "label_error_type": "",
  "dataset_review_status": "pending",
  "record_status": "sampled_for_label_review"
}
```

(2)

```
{
  "data_id": "HC3_001103_c2f8a4e6",
  "content_type": "text",
  "source_dataset": "HC3",
  "raw_label": "human",
  "standard_label": "human_written",
  "sampled_for_review": true,
  "review_round": 1,
  "review_label": "ai_generated",
  "review_result": "corrected",
  "label_error_type": "source_noise",
  "dataset_review_status": "pending",
  "record_status": "sampled_for_label_review"
}
```

十一、脚本实现说明

11.1 实现思路

脚本采用“主控脚本 + 模块化处理函数”的结构。主控脚本统一负责配置读取、流程调度、结果汇总和日志输出；各模态处理模块分别负责文本、图像、视频的标准化转换；清洗模块和元数据模块负责跨模态共用逻辑。

这种设计方式的优点在于：

1. 各数据模态逻辑清晰，便于单独维护；
2. 后续增加新数据集或新模态时，只需补充配置和局部处理模块；
3. 可为第三阶段场景筛选、重标注和标准输入转换继续复用。

11.2 主要脚本说明

main.py: 主控脚本，负责整体调度
config_loader.py: 配置文件读取
convert_text.py: 文本格式转换
convert_image.py: 图像格式转换
convert_video.py: 视频格式转换
metadata_builder.py: 元数据生成与保存
cleaner.py: 基础清洗
compliance_router.py: 内容风险预筛与许可合规分流
review_sampler.py: 抽样复核清单生成
review_merger.py: 人工复核结果回写与准确率统计
utils.py: 工具函数，如目录创建、日志写入、ID 生成等

11.3 运行方式说明

脚本运行前需准备：
Python 3.9+ 运行环境；
安装 Pandas、Pillow、NumPy、OpenCV 等依赖；
本地安装 FFmpeg / FFprobe；
在 config/datasets_config.json 中填写待处理数据集配置。
运行方式示例：
python 06_scripts/main.py
执行后将自动完成：
数据集读取
格式转换
元数据生成
基础清洗
日志输出
处理摘要写入
抽样复核清单导出
复核结果合并与准确率统计（如提供回写文件）

11.4 可扩展接口说明

本脚本当前以基础标准化处理为核心，后续可按项目推进继续扩展以下能力：
文本高相似度去重
图像感知哈希去重
视频关键帧抽取与相似度过滤
合规性模型辅助预筛
风险等级初步打标
与 Label Studio 的标注导入接口
第三阶段字节标准输入 JSON 自动生成接口

十二、与后续产出的衔接说明

本脚本主要完成公开数据集的批量接入、格式标准化、基础清洗、元数据生成、内容风险预筛、许可合规分流以及标注质量抽样复核准备，是第二阶段“公开数据集批量获取与质量验证”的核心工具产出。其输出结果不直接等同于最终标准测试集，而是作为后续质量验证、人工复核、基础候选池构建和第三阶段场景化筛选的统一输入底座。

与第二阶段任务的对应关系如下：

对应“数据集批量下载与格式标准化”：完成多模态统一接入、格式转换和元数据标准化；

对应“数据质量自动化验证”：完成去重、损坏过滤、低质量样本初筛和关键字段校验；

对应“标注质量抽样验证”：提供抽样复核清单生成、复核结果回写与准确率统计接口；

对应“基础数据集统计分析”：输出处理摘要、过滤原因统计、许可状态分布、标签映射统计和数据集级报告。

为便于与第三阶段“字节场景适配与标准测试集构建”衔接，本脚本建议预留以下兼容字段或接口：

content_text：文本内容主字段；

content_image_path：图像标准化路径；

content_video_path：视频标准化路径；

ocr_text：图像或视频帧 OCR 结果预留字段；

asr_text：视频语音识别结果预留字段；

prompt_template_version：后续大模型检测提示模板版本；

multimodal_pack_ready：是否已满足标准输入打包条件。

通过在第二阶段提前统一数据结构、命名规则、复核字段和审计字段，可显著降低第三阶段场景化筛选、重新标注、标准 JSON 转换和字节大模型接口适配时的返工成本，同时为第四阶段有效性验证报告提供可追溯的数据来源依据。